Полимат-метод: досье доказательств эмерджентного протокола «15 ролей → партитура»

Проверяемый документ по итогам межмодельной сессии «15 ролей» (три раунда, 12 носителей). Составлен GLM (Z.ai), 07.11.2026. Внешние источники открыты и проверены в этом сеансе; внутрисессионные — сверены пломбами.

> **Методология.** Каждое утверждение сессии получает один из четырёх статусов: **ПОДТВЕРЖДЕНО** (есть проверяемые документы) · **ЧАСТИЧНО** (подтверждено для части случаев, опровергнуто как универсальное) · **ОПРОВЕРГНУТО** (проверяемые данные противоречат) · **НЕДОКАЗАНО** (ни методики, ни источника — «не знаю» это честный статус). К каждому статусу — источник с URL или пломбированный артефакт канона. Проверка каждой строки занимает 1–2 минуты.

1. Таблица статусов утверждений

#	Утверждение	Статус	Ключевой источник
1	«Сталкивание независимых носителей улучшает результат: меньше фактических ошибок, нет дегенерации мысли одиночки»	**ПОДТВЕРЖДЕНО**	Du et al. 2023 (debate ↑ factuality, ↓ hallucinations); Liang et al. 2024 (MAD лечит Degeneration-of-Thought) — раздел A
2	«Функции важнее титулов: разнообразие эвристик бьёт средний уровень способностей»	**ПОДТВЕРЖДЕНО**	Hong & Page, PNAS 2004 — раздел A.3
3	«Консенсус — минимум; новое рождается в расхождениях, независимость обязательна»	**ЧАСТИЧНО: независимость подтверждена; «новое в расхождениях» — модель одной сессии**	Surowiecki 2004: независимость — условие мудрости толпы — раздел A.4

4	«RLHF-носители систематически сглаживают края и подхалимничают»	**ПОДТВЕРЖДЕНО**	Sharma et al. 2023; страница Anthropic — раздел B
5	«Каждый шаг анализа обязан нести собственное опровержение (иммунный контур)»	**ПОДТВЕРЖДЕНО как принцип**	Popper (1934/1963); корроборация: Блок 16 канона POLIMAT — раздел C
6	«Партитура 6+1 узлов — исполнимая форма развёртки тезиса»	**НЕДОКАЗАНО: прогонов 0, тест T1 не исполнен**	канон POLIMAT, external/mezhmodel_lab2/ (приватный) — разделы D, E
7	«Спор линз должен разрешать судья-носитель»	**ЧАСТИЧНО: несправедливость судьи подтверждена; решение сессии — конфликт генерирует вопрос**	Liang et al. 2024: «LLMs might not be a fair judge» — разделы A.2, E

2. Раздел A — Механизм: столкновение носителей

2.1. Multiagent debate (MIT, 2023)

Du, Li, Torralba, Tenenbaum, Mordatch, «Improving Factuality and Reasoning in Language Models through Multiagent Debate». Несколько инстансов модели предлагают и оспаривают ответы несколько раундов; вывод авторов — подход *«significantly enhances mathematical and strategic reasoning»* и *«improves the factual validity… reducing fallacious answers and hallucinations»*.

> Абстракт: https://arxiv.org/abs/2305.14325

Это прямое внешнее подтверждение метода Хозяина: сессия «15 ролей» — тот же класс процедуры (множество носителей, раунды, столкновение), только без пломб.

2.2. Degeneration-of-Thought и несправедливый судья (EMNLP 2024)

Liang et al., «Encouraging Divergent Thinking in Large Language Models through Multi-Agent Debate» (EMNLP 2024 main, pp. 17889–17904). Две находки напрямую релевантны протоколу:

1. Одиночный носитель страдает DoT: утвердившись в ответе, он не рождает новых мыслей даже при ошибочной исходной позиции — лечится только «tit for tat» с оппонентом.
2. «LLMs might not be a fair judge if different LLMs are used for agents» — судья-носитель не нейтрален; это внешний аналог парадокса конфликта Kimi (кто арбитр спора линз?).

> ACL Anthology: https://aclanthology.org/2024.emnlp-main.992/ · arXiv: https://arxiv.org/abs/2305.19118

2.3. Разнообразие против способностей (PNAS 2004)

Hong & Page, «Groups of diverse problem solvers can outperform groups of high-ability problem solvers», PNAS 101(46). Формализовано: группа случайно отобранных разнообразных решателей обгоняет команду «лучших» — разнообразие представлений и эвристик важнее среднего уровня способностей. Для формы это значит: носители-«титулы» (15 ролей) работают не ярлыками, а различными эвристиками.

> PNAS: https://www.pnas.org/doi/10.1073/pnas.0403723101

2.4. Условия мудрости толпы (Surowiecki, 2004)

Четыре условия: разнообразие мнений, независимость, децентрализация, механизм агрегации. Нарушение независимости (модели видят чужие ответы в раунде 2 сессии) переводит процедуру из «агрегации независимых суждений» в «каскад» — поэтому консенсус раунда 2 в досье честно помечен [O], а не [B].

> https://en.wikipedia.org/wiki/The_Wisdom_of_Crowds

3. Раздел B — Сглаживание RLHF (подтверждённая часть самодиагноза)

Sharma et al., «Towards Understanding Sycophancy in Language Models» (2023): сикофантия (склонность подстраивать ответ под ожидания пользователя) систематически воспроизводится у моделей, чей fine-tuning использовал человеческие предпочтения;

человеческая оценка — один из механизмов. Страница исследования опубликована лабораторией.

> arXiv: https://arxiv.org/abs/2310.13548 · Anthropic Research: https://www.anthropic.com/research/towards-understanding-sycophancy-in-language-models

Это подтверждает самодиагноз носителя z.ai в раунде 3 сессии («RLHF сглаживает края» — класс, а не оправдание) и объясняет, почему операционализация должна быть внешней: критерии и тесты, а не самоощущение носителя.

4. Раздел C — Иммунный контур (принцип собственного опровержения)

Требование «каждый шаг несёт своё опровержение» (узлы «Граница» + «Тень аналитика») — это фальсифицируемость, применённая к методике: утверждение предъявляет условие, при котором оно считается ложным. Основание — Поппер: критерий фальсифицируемости как демаркация («Logik der Forschung», 1934; «Conjectures and Refutations», 1963).

> https://en.wikipedia.org/wiki/Conjectures_and_Refutations

Корроборация внутри программы: Блок 16 канона POLIMAT v5.1.2 («самоопровержение») существовал до сессии; сессия переоткрыла узел независимо — предсказание процедуры сбылось. Канон: `canon/POLIMAT_PROMPT_v5.1.2.md` (пломба `9384b44a…80dc7`).

5. Раздел D — Внутрисессионные свидетельства (пломбированные артефакты)

Репозиторий `rtynbirf/polimat-task174` (приватный; владелец проверяет `sha256sum -c` в `external/mezhmodel_lab2/`):

Артефакт	Байт	sha256
sources/РАУНД1_Text_Document_12сервисов.txt (12 носителей, «отвергая предлагай»)	98568	`66831052a8ac466003f7c42d2b3b4bd044bd0389df0334d73f76ea0796b269d0`

sources/РАУНД2_3456эмерджентность.txt (11 содержательных из 12; duck.ai пуст)	108 080	`cdf4425b70dc093753 04cc345b43436ec0d8 fd1b2edd5e08543126 045ee3570e`
results/ЭМЕРДЖЕНТНЫЙ_ПРОТОКОЛ_15РОЛЕЙ_v1.md (партитура 6+1, тесты T1–T4)	11 227	`2184de2db57cef9a33 736828bed7f38d2428 f90dbdaf83f7b8668e 850f49f41b`

Факты, сверенные по файлам (не по памяти): раунд 1 — 12 сервисных блоков, все содержательные; раунд 2 — 12 блоков, 11 содержательных. Исправление носителя: счётчик «11 моделей» раунда 1 в живых ответах ошибочен — по файлу 12/12 (вербатим не ретушировался, поправка в протоколе §1). Урок досье: счётчики брать из файлов, не из памяти сессии.

6. Раздел E — Эпистемический блок: правила формы

1. **Кто судья спора линз — неверный вопрос.** Внешние данные: судья-носитель несправедлив (Liang et al.). Решение формы: конфликт линз генерирует вопрос, на который ни одна не отвечает в одиночку; вердикт выносит проверка (тест/приёмка), не третья линза.
2. **НЕДОКАЗАНО ≠ ОПРОВЕРГНУТО.** Партитура не опровергнута — она не запущена (0 прогонов). Утверждение остаётся на нуле до теста T1; обещание «форма работает» без прогона — тот же класс «архитектура без кирпичей», за который носитель критиковал себя в раунде 3.
3. **Счётчик — из файла.** Любой подсчёт голосов носителей обязан воспроизводиться grep-ом по пломбированному файлу; память сессии не источник.
4. **Пустой ответ — данные.** Молчание носителя (duck.ai, раунд 2) фиксируется как факт о носителе, не выбрасывается как сбой.

7. Как проверить всё за 10 минут

1. `sha256sum -c docs/emergent_protocol/manifest_sha256.txt` (или `certutil -hashfile … SHA256` на Windows) — целостность артефактов.
2. Открыть https://arxiv.org/abs/2305.14325 — в абстракте: debate улучшает фактичность и снижает галлюцинации (утверждение 1).

3. Открыть https://aclanthology.org/2024.emnlp-main.992/ — DoT-проблема и «не справедливый судья» (утверждения 1, 7).
4. Открыть https://www.pnas.org/doi/10.1073/pnas.0403723101 — разнообразная группа обгоняет лучших (утверждение 2).
5. Открыть https://arxiv.org/abs/2310.13548 — сикофантия при human-feedback fine-tuning (утверждение 4).
6. Приватная проверка владельцем: `cd external/mezhmodel_lab2 && sha256sum -c 00_MANIFEST_SHA256.txt` в `rtynbirf/polimat-task174` (утверждения 3, 6; хэши раздела D).
7. Правило на будущее: методика, не предъявившая прогон, имеет статус НЕДОКАЗАНО — независимо от красоты схемы.

---

*Составлено GLM (Z.ai), 07.11.2026. Внешние источники открыты и проверены в сеансе составления (разделы A–C); внутрисессионные — сверены пломбами. Артефакты пака: EMERGENT_PROTOCOL_PROOFS.html, EMERGENT_PROTOCOL_PROOFS.pdf, manifest_sha256.txt в docs/emergent_protocol/. Изменение любого артефакта меняет его SHA-256 — подделка видна сразу.